

最终 YOLO Loss 设计：公式、例子与基础概念

1. 最终 Loss 完整数学公式

我们最终使用的是双尺度 YOLO-style detection loss。模型输出 p4 和 p5 两个尺度，每个尺度每个 grid cell 有 3 个 anchors，每个 anchor 输出 4 个 bbox 参数、1 个 objectness logit 和 80 个 class logits。

```
pred_p4: [B, 26, 26, 255]
pred_p5: [B, 13, 13, 255]
255 = 3 * (4 bbox + 1 objectness + 80 classes)
```

最终总 loss 是两个尺度 loss 的和：

```
L_total = L_p4 + L_p5
```

单个尺度的 loss 为：

```
L_scale = lambda_box * L_box + lambda_obj * L_obj + lambda_cls * L_cls
```

最终超参数选择为：lambda_box=5.0，lambda_obj=1.0，lambda_cls=1.0，lambda_noobj=1.0。因此：

```
L_scale = 5.0 * L_box + L_obj + L_cls
L_obj = L_obj_pos + 1.0 * L_obj_neg
```

展开到双尺度后，最终训练目标是：

```
L_total = [5 * L_box_p4 + L_obj_p4 + L_cls_p4]
          + [5 * L_box_p5 + L_obj_p5 + L_cls_p5]
```

Dynamic Assignment

在计算 loss 前，需要先决定哪些 prediction slot 是正样本。一个 slot 表示 (grid_y, grid_x, anchor_index)。最终使用 dynamic_cost，而不是固定静态分配。

```
cost = 3.0 * (1 - IoU(pred_box, gt_box)) + 1.0 * BCE(pred_cls, gt_class)
```

候选区域由 dynamic_center_radius=1 控制，即 GT 中心 grid 周围 3x3 区域。每个 cell 有 3 个

最终 YOLO Loss 设计：公式、例子与基础概念

GT 的 IoU $\geq$ dynamic_ignore_iou=0.5, 则它不会被当作普通背景参与 no-object loss。

Box Loss

记动态分配后的正样本集合为 P 。对于正样本 i , 预测框为 pred_box_i , GT 框为 gt_box_i 。box loss 使用

GIoU :

$$L_{\text{box}} = (1 / |P|) * \sum_{i \in P} [1 - \text{GIoU}(\text{pred_box}_i, \text{gt_box}_i)]$$

当预测框越接近 GT 框时, GIoU 越接近 1, 因此 $1 - \text{GIoU}$ 越接近 0, box loss 越小。

Objectness Loss

最终 objectness 正样本 target 不是固定 1, 而是当前预测框与 GT 的 IoU, 并设置下限 0.05 :

$$\begin{aligned} q_i &= \text{clamp}(\text{IoU}(\text{pred_box}_i, \text{gt_box}_i), \text{min}=0.05, \text{max}=1.0) \\ L_{\text{obj_pos}} &= (1 / |P|) * \sum_{i \in P} \text{BCEWithLogits}(\text{obj_logit}_i, q_i) \\ L_{\text{obj_neg}} &= (1 / |N|) * \sum_{j \in N} \text{BCEWithLogits}(\text{obj_logit}_j, 0) \\ L_{\text{obj}} &= L_{\text{obj_pos}} + 1.0 * L_{\text{obj_neg}} \end{aligned}$$

这样 objectness 不只表示有没有物体, 也和框质量绑定。框质量越高, objectness target 越高。

Classification Loss

最终分类使用 quality BCE。BCE 公式没有变化, 但 target 从普通 one-hot 改成 IoU quality

target。若正样本 i 的 GT 类别为 c_i :

$$\begin{aligned} t_{\{i,k\}} &= \text{IoU}(\text{pred_box}_i, \text{gt_box}_i), \text{ if } k = c_i \\ &= 0, \text{ otherwise} \\ L_{\text{cls}} &= (1 / (|P| * C)) * \sum_{i \in P} \sum_{k=1}^C \text{BCEWithLogits}(\text{cls_logit}_{\{i,k\}}, t_{\{i,k\}}) \\ C &= 80 \end{aligned}$$

这意味着分类置信度也会受到定位质量约束。预测框质量低时, 即使类别方向正确, 分类 target 也不会是满分 1。

最终 YOLO Loss 设计：公式、例子与基础概念

```
pred = [bbox_raw_1, bbox_raw_2, bbox_raw_3, bbox_raw_4, obj_logit,  
        cls_logit_1, ..., cls_logit_80]  
length = 85 = 4 + 1 + 80
```

假设 bbox decode 后：

```
pred_box = [0.40, 0.40, 0.70, 0.70]  
gt_box   = [0.45, 0.45, 0.75, 0.75]  
gt_class = dog  
obj_logit = 1.2  
dog class logit = 2.0  
other 79 class logits = -2.0
```

IoU 计算

交集框为 [0.45, 0.45, 0.70, 0.70]，交集面积为 $0.25 \times 0.25 = 0.0625$ 。预测框面积为 $0.30 \times 0.30 = 0.09$ ，GT 框面积同样为 0.09。

```
union_area = 0.09 + 0.09 - 0.0625 = 0.1175  
IoU = 0.0625 / 0.1175  $\approx$  0.5319
```

GIoU 与 Box Loss

最小外接框为 [0.40, 0.40, 0.75, 0.75]，面积为 $0.35 \times 0.35 = 0.1225$ 。

```
GIoU = IoU - (C_area - union_area) / C_area  
      = 0.5319 - (0.1225 - 0.1175) / 0.1225  
       $\approx$  0.4911
```

```
L_box = 1 - Giou = 1 - 0.4911 = 0.5089
```

Objectness Loss

正样本 objectness target 为 IoU soft target：

```
q = clamp(0.5319, 0.05, 1.0) = 0.5319  
L_obj_pos = BCEWithLogits(1.2, 0.5319)  $\approx$  0.8250
```

假设有一个负样本 slot，objectness logit 为 -1.0，target 为 0：

最终 YOLO Loss 设计：公式、例子与基础概念

```
L_obj_neg = BCEWithLogits(-1.0, 0) ≈ 0.3133
L_obj = 0.8250 + 1.0 * 0.3133 = 1.1383
```

Classification Loss

dog 类 target 为 IoU=0.5319，其他 79 类 target 为 0。

```
BCEWithLogits(2.0, 0.5319) ≈ 1.0631
BCEWithLogits(-2.0, 0) ≈ 0.1269
79 * 0.1269 ≈ 10.0251
L_cls = (1.0631 + 10.0251) / 80 ≈ 0.1386
```

单尺度总 Loss

```
L_scale = 5 * L_box + L_obj + L_cls
          = 5 * 0.5089 + 1.1383 + 0.1386
          ≈ 3.8214
```

这个例子说明：box loss 权重最大；objectness 同时考虑正负样本；classification 的正确类别 target 是 IoU，而不是固定 1。

3. IoU、GIoU、BCE 分别是什么

IoU

IoU 是 Intersection over Union，即交并比。它衡量预测框和真实框的重叠程度。

$$\text{IoU}(A, B) = \text{area}(A \cap B) / \text{area}(A \cup B)$$

IoU 取值在 0 到 1 之间。完全重合时 IoU=1，完全不重合时 IoU=0。

GIoU

GIoU 是 Generalized IoU。它在 IoU 基础上加入最小外接框惩罚。

$$\text{GIoU}(A, B) = \text{IoU}(A, B) - (\text{area}(C) - \text{area}(A \cup B)) / \text{area}(C)$$

其中 C 是同时包住 A 和 B 的最小外接框。GIoU 的优势是：即使两个框不重叠，仍然可以通过外接框惩罚反映两个框之间的距离。

BCE

BCE 是 Binary Cross Entropy，即二分类交叉熵。若预测概率为 p ，target 为 y ：

$$\text{BCE}(p, y) = - [y * \log(p) + (1 - y) * \log(1 - p)]$$

代码中使用 BCEWithLogitsLoss，输入是 logit z ，而不是概率。它内部会先做 sigmoid：

$$p = \text{sigmoid}(z) = 1 / (1 + \exp(-z))$$

$$\text{BCEWithLogits}(z, y) = \text{BCE}(\text{sigmoid}(z), y)$$

我们在 objectness 和 classification 两处使用 BCE。最终 target 是 quality

target：objectness target 等于 IoU，classification 正类 target 也等于 IoU。

总结

最终 loss 的核心设计是：用 dynamic assignment 根据当前预测质量选择正样本；用 GloU 监督框定位；用 IoU

soft target 监督 objectness；用 quality BCE 监督 classification；最后把 p4 和 p5

双尺度 loss 相加。

$$L_{\text{total}} = L_{\text{p4}} + L_{\text{p5}}$$

$$L_{\text{scale}} = 5 * L_{\text{box}} + L_{\text{obj}} + L_{\text{cls}}$$