

检查点06 阶段总结报告 (Version 02)

从完整Loss 升级到三框机制Round 4B

2026-04-19

Contents

1	报告范围与前置背景	2
1.1	本报告覆盖范围	2
1.2	Version 01 到Version 02 的转移原因	2
2	统一训练协议、数据集与检测方法	2
2.1	统一数据来源	2
2.2	统一训练超参数	3
2.3	当前使用的检测方法	3
3	当前主模型结构：以Round 4B 的deep_residual 为例	4
3.1	Backbone 结构	4
3.2	空间尺寸变化	5
3.3	当前主模型参数量	5
4	从简化MSE 到完整YOLO-style loss 的设计升级	5
4.1	升级动机	5
4.2	Version 02 的基础loss 设计	6
4.3	从Stage A 到当前Round 4B 的loss 设计演化	6
5	Stage A: deep_cnn + single-box full loss	7
5.1	实验目标	7
5.2	对应实验与配置	7
5.3	Loss 曲线与结果	7
5.4	阶段结论与转移	8
6	Stage B: deep_residual + single-box full loss	8
6.1	实验目标	8
6.2	对应实验与配置	8
6.3	结果	9
6.4	阶段结论与转移	9
7	Stage C: 三框检测头的设计与连续改进	9
7.1	Stage C 原始设计	9
7.2	Stage C 各轮正式实验的Loss 曲线	11
7.3	Stage C 各轮实验与结果总表	12
7.4	Round 1: YOLOv5 风格box 参数化与IoU soft objectness	12
7.5	Round 2: 重构分配逻辑	12
7.6	Round 3B: soft objectness 保底	13

7.7	Round 3C: shape-matching	13
7.8	Round 4A: 收紧shape ratio 与objectness 下限	13
7.9	Round 4B: ignore band 真正生效	14
8	当前Stage C 的评估趋势	14
9	当前版本的可视化结果	15
10	截至Round 4B 的阶段结论	17
10.1	已经完成的关键结论	17
10.2	当前最强基线	18
10.3	下一步方向	18
A	附录: Version 02 涉及的正式实验与结果索引	18

1 报告范围与前置背景

1.1 本报告覆盖范围

本报告只总结checkpoint06_version01 之后的内容，重点覆盖：

1. 从简化MSE 检测目标转向完整YOLO-style loss 的过程；
2. 在完整loss 下比较deep_cnn 与deep_residual；
3. 三框检测头从初版到Round 4B 的连续改进；
4. 与这些实验对应的训练曲线、评估指标和可视化结果。

因此，本报告不再重复第一版报告中已经单独总结过的Backbone 早期探索细节，而是把Version 01 的结论作为出发点。

1.2 Version 01 到Version 02 的转移原因

在Version 01 对应的阶段中，Backbone 对比已经得到一个清晰结论：

- 在简化MSE loss 下，deep_cnn 是最合适的后续主干起点；
- resnet18_like 结构更规范，但在当时的训练目标下泛化较差；
- 当前系统的主要瓶颈已经不再只是Backbone，而是检测训练目标本身。

因此，从Version 02 开始，工作重心转向：

先升级loss，再在统一loss 下比较残差连接，最后把重点放到三框检测头、anchor 匹配和objectness 机制上。

2 统一训练协议、数据集与检测方法

2.1 统一数据来源

从完整loss 阶段开始，到当前Round 4B 为止，正式实验一直使用Unified 的full manifest：

- 训练集： /home/lidz/YOLO/DataSet/Unified/manifests/all_train.jsonl
- 验证集： /home/lidz/YOLO/DataSet/Unified/manifests/all_val.jsonl

输入处理流程保持一致：

- 读取原始RGB 图像；
- resize 到320 x 320；
- 将真实框同步缩放到新的图像尺度；
- 再编码成网格监督张量。

当前阶段不引入随机数据增广，原因是需要严格控制变量，把结构变化和loss 变化的影响分开。

2.2 统一训练超参数

从Stage A 到当前Round 4B，大部分正式实验都共享表1 中的训练协议。

Table 1: Version 02 阶段共享训练协议

项目	设置
训练manifest	all_train.jsonl
验证manifest	all_val.jsonl
打包格式	pt
输入尺寸	320 x 320
输出网格	10 x 10
类别数	80
batch size	256
epochs	20
优化器	AdamW
学习率	1e-3
最小学习率	1e-5
权重衰减	1e-4
调度器	cosine
DataLoader workers	64
多卡方式	DataParallel
正式结果来源	full training only

2.3 当前使用的检测方法

当前所有full-loss 检测实验都采用单尺度检测器：

- 输入张量形状：[B, 3, 320, 320]
- 输出网格：10 x 10

单框阶段：

- 输出张量：[B, 10, 10, 85]
- 每个cell 预测：
 - 4 个box 参数
 - 1 个objectness
 - 80 个类别logits

三框阶段：

- 输出张量：[B, 10, 10, 255]
- 每个cell 的255 维会reshape 为：

$$[B, 10, 10, 3, 85]$$

- 即每个cell 含3 个anchor 槽位，每个槽位各自预测：
 - 4 个box 参数

- 1 个objectness
- 80 个类别logits

当前推理流程为:

1. 解码`tx`, `ty`, `tw`, `th` 得到归一化预测框;
2. 对`obj` 和`cls` 分别做`sigmoid`;
3. 用:

$$score = obj \times \max(\text{class score})$$

作为排序分数;

4. 做class-wise NMS;
5. 输出可视化图像, 其中绿色为GT, 红色为预测框。

3 当前主模型结构: 以Round 4B 的`deep_residual` 为例

3.1 Backbone 结构

当前主模型的Backbone 仍然是:

- `deep_residual`

该模型使用`BaselineBackbone` 家族, 配置为:

- `width_mult = 1.0`
- `depth_mult = 2.0`
- `use_residual = true`

在实现上, 这意味着:

- 共有6 个stage, 通道分别为:

32, 64, 128, 256, 384, 512

- 每个stage 有4 个`ConvBNAct`;
- 从第3 个stage 开始, 每个stage 末尾增加1 个轻量残差块;
- 每个轻量残差块内部含2 个卷积块。

因此, 仅从卷积块数量看:

- 主干卷积块: $6 \times 4 = 24$
- 残差分支额外卷积块: $4 \times 2 = 8$
- Head 中额外2 个卷积层

总计约为:

34 个卷积层量级的检测网络。

3.2 空间尺寸变化

对于输入:

$$[B, 3, 320, 320]$$

空间尺寸演化大致如下:

Table 2: 当前deep_residual 的主要张量形状变化

模块	结构说明	输出张量
输入	RGB 图像	[B, 3, 320, 320]
Stage 1	4 个32 通道卷积+ pool	[B, 32, 160, 160]
Stage 2	4 个64 通道卷积+ pool	[B, 64, 80, 80]
Stage 3	4 个128 通道卷积+ 残差+ pool	[B, 128, 40, 40]
Stage 4	4 个256 通道卷积+ 残差+ pool	[B, 256, 20, 20]
Stage 5	4 个384 通道卷积+ 残差+ pool	[B, 384, 10, 10]
Stage 6	4 个512 通道卷积+ 残差	[B, 512, 10, 10]
Head Conv	512 -> 256	[B, 256, 10, 10]
Pred Conv	256 -> 255	[B, 255, 10, 10]
输出重排	permute	[B, 10, 10, 255]

3.3 当前主模型参数量

在当前Round 4B 配置下, 模型总参数量为:

$$26.56M$$

这一数值在Version 02 的各轮三框实验中保持不变, 因此后续比较主要来自:

- loss 设计变化;
- box 参数化变化;
- anchor 分配和ignore 机制变化;
- objectness 监督变化。

4 从简化MSE 到完整YOLO-style loss 的设计升级

4.1 升级动机

在Version 01 之前, 检测器主要依赖:

- 分类MSE
- 框回归MSE

该损失能支持早期Backbone 对比, 但与真实检测任务之间仍有明显差距:

- 没有objectness;
- 没有no-object 约束;
- box loss 不是几何一致性的IoU/GIoU;
- 分类监督也较为粗糙。

因此, 从Stage A 开始, 我们将损失升级为更完整的YOLO-style 形式。

4.2 Version 02 的基础loss 设计

单框完整loss 的设计如下：

- `loss_box`: 使用 $1 - \text{GIoU}$
- `loss_obj`: 使用 `BCEWithLogits`
- `loss_cls`: 使用 `BCEWithLogits + one-hot`

总损失为：

$$L = \lambda_{box} L_{box} + \lambda_{obj} L_{obj} + \lambda_{cls} L_{cls}$$

其中：

$$L_{obj} = L_{obj}^{pos} + \lambda_{noobj} L_{obj}^{neg}$$

Version 02 的固定权重为：

- $\lambda_{box} = 5.0$
- $\lambda_{obj} = 1.0$
- $\lambda_{noobj} = 0.5$
- $\lambda_{cls} = 1.0$

4.3 从Stage A 到当前Round 4B 的loss 设计演化

这条线可以概括为表3。

Table 3: Version 02 的loss 与检测头演化

阶段	输出形式	主要改动
Stage A	单框85 维	引入objectness, box 改为GIoU, 分类改为BCE
Stage B	单框85 维	loss 不变, 只切换到 <code>deep_residual</code>
Stage C	三框255 维	初版三框head, 引入anchors 和多框supervision
Base		
Round 1	三框255 维	引入YOLOv5 风格box 参数化, 加入IoU soft objectness
Round 2	三框255 维	重构分配逻辑与三态supervision 框架
Round 3B	三框255 维	对soft objectness 增加下限, 缓解冷启动过度保守
Round 3C	三框255 维	用shape-matching 替换IoU-matching, 激活三框的shape 覆盖能力
Round 4A	三框255 维	收紧shape ratio 与soft objectness min, 减少多余框
Round 4B	三框255 维	引入真实生效的ignore band, 建立pos/ignore/neg 三态

5 Stage A: deep_cnn + single-box full loss

5.1 实验目标

Stage A 的目标是:

在冻结deep_cnn Backbone 的前提下, 验证完整单框YOLO-style loss 是否稳定可训练。

5.2 对应实验与配置

- 配置: configs/deep_cnn_single_box_full_loss.toml
- run_id: deep_cnn_single_box_full_loss_20260419_020616
- 结果: logs/records/deep_cnn_single_box_full_loss_20260419_020616/result.txt

5.3 Loss 曲线与结果




Figure 1: Stage A 与Stage B 的train/val 总损失曲线。左图为Stage A, 右图为Stage B。




Figure 2: Stage A 与Stage B 的验证集loss_box、loss_obj 和loss_cls 曲线。

Stage A 的关键结果如下:

Table 4: Stage A 正式结果

指标	数值
参数量	17.66M
最优epoch	14
最优验证总损失	2.391537
internal mAP@0.5	0.023312
internal precision	0.040590
internal recall	0.190877
COCO AP50	0.000486
COCO AR@100	0.001081
FPS	142.24

5.4 阶段结论与转移

Stage A 成功证明:

- 完整单框loss 可以稳定训练;
- `loss_box`、`loss_obj`、`loss_cls` 均能下降;
- 检测器已经不再是早期教学式MSE 原型。

但Stage A 只完成了loss 升级本身, 并不能回答:

- 在同样的完整loss 下, 残差连接是否有帮助?

因此, 下一阶段转入Stage B, 在不改变loss 的前提下, 只比较Backbone 的残差效应。

6 Stage B: deep_residual + single-box full loss

6.1 实验目标

Stage B 的目标是:

在与Stage A 完全相同的完整loss 下, 只改变Backbone, 把`deep_cnn`替换为`deep_residual`, 观察残差连接的收益。

6.2 对应实验与配置

- 配置: `configs/deep_residual_single_box_full_loss.toml`
- `run_id`: `deep_residual_single_box_full_loss_20260419_031404`
- 结果: `logs/records/deep_residual_single_box_full_loss_20260419_031404/result.txt`

6.3 结果

Table 5: Stage A 与Stage B 的关键对比

指标	Stage A	Stage B
参数量	17.66M	26.52M
最优验证总损失	2.391537	2.351891
internal mAP@0.5	0.023312	0.028802
internal precision	0.040590	0.046880
internal recall	0.190877	0.201682
COCO AP50	0.000486	0.000588
COCO AR@100	0.001081	0.001211
FPS	142.24	122.19

6.4 阶段结论与转移

Stage B 的结论非常明确:

- 在完整单框loss 下, 残差连接是有效的;
- `deep_residual` 在效果上显著优于`deep_cnn`;
- 因此, `deep_residual + single-box full loss` 成为后续最强实用基线。

但单框方案仍然存在先天限制:

- 一个cell 只能分配一个框;
- 对同cell 多目标和多种尺度/长宽比目标的表达能力有限。

因此, 下一步自然转向Stage C: 在固定`deep_residual` 的基础上, 把检测头从单框升级成三框。

7 Stage C: 三框检测头的设计与连续改进

7.1 Stage C 原始设计

Stage C 的原始版本对应实验:

- 配置: `configs/deep_residual_three_box_full_loss.toml`
- `run_id: deep_residual_three_box_full_loss_20260419_043041`

原始三框方案的设计如下:

- 每个cell 预测3 个anchor 槽位;
- 输出形状:

$$[B, 10, 10, 255]$$

- 其中:

$$255 = 3 \times (80 + 5)$$

- 初始anchor:

$$(0.052141, 0.076305), (0.199926, 0.288289), (0.609263, 0.649287)$$

- 初始匹配规则仍然相对保守;
- objectness 还未引入更强的质量感知。

Stage C 原始版本的结果是:

Table 6: Stage C 初版结果

指标	数值
最优验证总损失	2.956484
internal mAP@0.5	0.016119
internal precision	0.015502
internal recall	0.166946
COCO AP50	0.000122
COCO AR@100	0.000999

这一结果表明:

三框机制虽然已经能训练, 但初始版本远弱于单框残差基线, 必须进入连续改进。

7.2 Stage C 各轮正式实验的Loss 曲线




Figure 3: Stage C 所有正式实验的train/val 总损失曲线。每个子图对应一个正式实验，顺序为：Stage C Base、Round 1、Round 2、Round 3B、Round 3C、Round 4A、Round 4B。

7.3 Stage C 各轮实验与结果总表

Table 7: Stage C 各轮正式实验结果总表

实验	Best Val	mAP@0.5	Prec.	Recall	AP50	AR@100
Stage C Base	2.9565	0.01612	0.01550	0.16695	0.000122	0.000999
Round 1	2.5310	0.02186	0.02686	0.19999	0.000299	0.001134
Round 2	2.6409	0.02426	0.03602	0.20033	0.000286	0.001014
Round 3B	2.6738	0.02072	0.02841	0.20020	0.000296	0.001090
Round 3C	2.5851	0.02392	0.03507	0.20117	0.000343	0.001332
Round 4A	2.6210	0.02179	0.03576	0.19999	0.000496	0.001103
Round 4B	2.6260	0.02302	0.03367	0.20216	0.000432	0.001175

7.4 Round 1: YOLOv5 风格box 参数化与IoU soft objectness

Round 1 的改动是:

- 将box 参数化升级为更接近YOLOv5 风格;
- 引入IoU-based soft objectness target。

这一轮的主要作用是:

- 让三框线从“基本能训”推进到“能更像检测器一样打分”;
- 明显改善初版Stage C 的精度和召回。

它把COCO AP50 从:

$$0.000122 \rightarrow 0.000299$$

说明Round 1 是Stage C 的第一次有效激活。

7.5 Round 2: 重构分配逻辑

Round 2 主要重写了anchor 分配与监督逻辑, 使三框不再完全退化为带多个槽位的单框模型。
结果上, Round 2 的特点是:

- internal mAP@0.5 上升到0.02426;
- precision 提升到0.03602;
- 但COCO AP50 没有继续上升, 反而略退。

这说明:

Round 2 的分配重构在内部指标上有效, 但在更严格的官方风格评测下, 还不是决定性胜利。

7.6 Round 3B: soft objectness 保底

Round 3B 的主要改动是：

- 在soft objectness target 上增加下限，缓解冷启动阶段过于保守的问题。

这一轮的主要作用更偏向稳定性：

- 训练更稳；
- COCO AP50 回升到接近Round 1；
- 但整体质量仍未超过单框残差基线。

7.7 Round 3C: shape-matching

Round 3C 是Stage C 中非常关键的一步：

- 将正样本匹配标准从IoU 匹配改为shape-matching；
- 让形状合适的anchor 更容易成为正样本候选。

它带来的结果是：

- COCO AR@100 上升到0.001332；
- internal recall 上升到0.201168；
- 说明三框的覆盖能力被真正激活。

但与此同时：

- 预测框数量也开始偏多；
- 可视化中出现明显的“一物多框”和套娃框。

因此，Stage C 从此进入“收紧而不是继续放宽”的阶段。

7.8 Round 4A: 收紧shape ratio 与objectness 下限

Round 4A 只改配置，不改核心逻辑：

- anchor_shape_ratio: 4.0 -> 2.5
- soft_objectness_min: 0.4 -> 0.05

它的结果很有代表性：

- 预测框数量减少；
- precision 上升；
- COCO AP50 提升到0.000496；
- 但recall 和AR@100 略有回落。

这表明：

Round 4A 是一个明显的“精度导向收紧版”。

7.9 Round 4B: ignore band 真正生效

Round 4B 的唯一主变量是:

- 在shape-matching 分支中引入独立的`anchor_ignore_shape_ratio = 4.0`

从训练记录看, Round 4B 首次让:

- `ignored_count > 0`

说明`positive / ignore / negative` 三态终于真正成立。
这一轮的效果是:

- internal recall 提升到0.202157;
- COCO AR@100 回升到0.001175;
- internal mAP@0.5 回升到0.023020;
- 但precision 和AP50 低于Round 4A;
- 预测框数量重新上升。

因此, Round 4B 应被理解为:

一个召回导向的三框版本, 它证明ignore band 有意义, 但还没有同时把排序质量也做好。

8 当前Stage C 的评估趋势




Figure 4: Stage C 各轮正式实验的内部评估趋势, 包括mAP@0.5、precision、recall 和预测框总数。




Figure 5: Stage C 各轮正式实验在COCO 子集官方风格评测下的AP50 和AR@100。

从图4 和图5 可以看到，Stage C 当前已经进入比较清晰的权衡状态：

- Round 4A 更强调减少冗余框、提升AP50；
- Round 4B 更强调恢复召回、让ignore band 生效；
- 但两者都还没有全面超过当前最强单框基线。

9 当前版本的可视化结果


为了更直观地观察Round 4A 和Round 4B 的差别，本节同时给出两轮实验在同一组固定验证样本上的可视化结果。图中：

- 绿色框为真实框；
- 红色框为预测框。

这些图像说明，当前三框版本已经具备较强的覆盖能力，但在不同配置下呈现出不同的误检-召回权衡：

- Round 4A 更倾向于压缩候选框数量，画面更干净；
- Round 4B 由于ignore band 生效，往往会保留更多候选框；
- 两轮都仍然存在部分目标周围的套娃框，说明排序质量仍有进一步提升空间。


voc2012_val_2008_000002



voc2012_val_2008_000003



voc2012_val_2008_000007



voc2012_val_2008_000009




Figure 6: Round 4A 的四张固定可视化样本。




Figure 7: Round 4B 的四张固定可视化样本。

10 截至Round 4B 的阶段结论

10.1 已经完成的关键结论

截至当前，Version 02 阶段已经完成如下结论：

1. 完整单框YOLO-style loss 已经稳定可用；
2. 在完整单框loss 下，`deep_residual` 明显优于`deep_cnn`；
3. 三框检测头已经从“能训但明显弱”逐步推进到“召回能力被真正激活”；
4. `shape-matching` 是Stage C 中最关键的有效改动之一；
5. Round 4A 与Round 4B 分别代表了：

- 精度导向的收紧版;
- 召回导向的ignore-band 版;

6. 当前三框版本仍未全面超过:

`deep_residual + single-box full loss`

这一最强实用基线。

10.2 当前最强基线

当前最强实用基线仍然是:

- `deep_residual_single_box_full_loss`

它在当前所有Version 02 实验中, 仍然拥有:

- 更高的internal mAP@0.5;
- 更高的internal precision;
- 更高的COCO AP50。

10.3 下一步方向

Stage C 当前最主要的问题, 已经不是:

- 框根本出不来;
- anchor 完全不匹配;
- backbone 不够强。

而是:

- 多框下的排序质量;
- objectness 与框质量之间的耦合;
- 如何让好框拿更高分、坏框自然死亡。

因此, 下一步最合理的方向不是继续改Backbone, 而是继续围绕:

`objectness / scoring quality`

做更受控的Stage C 改进。

A 附录: Version 02 涉及的正式实验与结果索引

表8 列出了本报告涉及的全部正式实验, 以及它们对应的配置文件、run_id 和结果文件。

Table 8: Version 02 正式实验索引

实验	配置文件	run.id	结果文件
Stage A	configs/deep_cnn_single_box_full_loss.toml	deep_cnn_single_box_full_loss_20260419_020616	logs/records/deep_cnn_single_box_full_loss_20260419_020616/result.txt
Stage B	configs/deep_residual_single_box_full_loss.toml	deep_residual_single_box_full_loss_20260419_031404	logs/records/deep_residual_single_box_full_loss_20260419_031404/result.txt
Stage C Base	configs/deep_residual_three_box_full_loss.toml	deep_residual_three_box_full_loss_20260419_043041	logs/records/deep_residual_three_box_full_loss_20260419_043041/result.txt
Round 1	configs/deep_residual_three_box_v5box_softobj.toml	deep_residual_three_box_v5box_softobj_20260419_135531	logs/records/deep_residual_three_box_v5box_softobj_20260419_135531/result.txt
Round 2	configs/deep_residual_three_box_v5box_softobj_assign.toml	deep_residual_three_box_v5box_softobj_assign_20260419_152713	logs/records/deep_residual_three_box_v5box_softobj_assign_20260419_152713/result.txt
Round 3B	configs/deep_residual_three_box_v5box_softobj_clamp.toml	deep_residual_three_box_v5box_softobj_clamp_20260419_171735	logs/records/deep_residual_three_box_v5box_softobj_clamp_20260419_171735/result.txt
Round 3C	configs/deep_residual_three_box_v5box_softobj_shapematch.toml	deep_residual_three_box_v5box_softobj_shapematch_20260419_184314	logs/records/deep_residual_three_box_v5box_softobj_shapematch_20260419_184314/result.txt
Round 4A	configs/deep_residual_three_box_v5box_softobj_shapematch_tight.toml	deep_residual_three_box_v5box_softobj_shapematch_tight_20260419_201922	logs/records/deep_residual_three_box_v5box_softobj_shapematch_tight_20260419_201922/result.txt
Round 4B	configs/deep_residual_three_box_v5box_softobj_shapematch_ignore.toml	deep_residual_three_box_v5box_softobj_shapematch_ignore_20260419_215025	logs/records/deep_residual_three_box_v5box_softobj_shapematch_ignore_20260419_215025/result.txt